

Predicción de Superficies de Volatilidad Implícita en Mercados Latinoamericanos: Un Enfoque Funcional

Autor: Henri Paul Camayo Guillermo, henri.camayo@pucp.pe

Asesora: Dra. Felícita Doris Miranda Huaynalaya, fdmirandah@pucp.edu.pe

15 de diciembre de 2025

Índice

1. Introducción	3
1.1. Objetivos de la Tesis	6
1.2. Organización del Trabajo	6
2. Conceptos básicos sobre opciones y superficies de volatilidad implícita	7
2.1. Opciones <i>vanilla</i>	7
2.2. Relación <i>moneyness</i>	7
2.3. Volatilidad implícita (VI)	8
2.4. Superficie de volatilidad implícita (SVI)	8
2.5. Patrones típicos	8
3. Metodología	9
3.1. Análisis de Datos Funcionales (FDA)	9
3.2. Espacio de Hilbert	9
3.3. Aproximación funcional mediante bases B-spline	11
3.4. Base tensorial B-spline para superficies bidimensionales	13
3.5. Descomposición en Componentes Principales Funcionales (FPCA) sobre superficies bidimensionales	16
3.6. Regresión kernel en puntajes FPCA con errores ARH(1)	18
3.7. Modelos de referencia	22
3.7.1. Persistencia en la malla observada (PM)	23
3.7.2. Persistencia de la superficie ajustada (PA)	23
3.7.3. Autorregresivo vectorial de orden 1 en puntajes (VAR(1))	23
3.7.4. ARH(1) en incrementos de puntajes (ARH-inc)	24
3.7.5. Resumen de modelos y comparabilidad	24
4. Aplicación: Componentes Principales Funcionales de las SVI	25
4.1. Descripción de los Datos	25

4.2. Preprocesamiento y conformación del panel	27
4.3. Ajuste diario sobre base B-spline tensorial	27
4.4. FPCA de superficies en la métrica funcional	29
5. Modelos dinámicos en puntajes FPCA con dependencia autorregresiva	33
5.1. Diseño del backtest OOS y modelos comparados	34
5.2. Elección de K_0	34
5.3. Resultados principales OOS	35
5.4. Robustez: distribución de errores y tasa de aciertos	36
6. Conclusiones	38
6.1. Limitaciones	40
6.2. Líneas de investigación futura	40

1. Introducción

En los mercados de derivados financieros, la superficie de volatilidad implícita (SVI) representa la estructura tridimensional que asigna un nivel de volatilidad a cada combinación de precio de ejercicio y vencimiento de una opción cotizada. Esta superficie, inferida a partir de los precios de mercado, constituye una herramienta crítica para el cálculo de los precios de opciones, la cobertura de riesgos y la búsqueda de oportunidades de arbitraje. Sin embargo, los mercados de opciones de América Latina presentan características estructurales que dificultan su modelamiento: poca liquidez y variedad de opciones, precios de ejercicio irregulares y diferenciales bid-ask (precios de compra-venta) significativos. En este contexto, disponer de pronósticos confiables de la SVI no solo mejora los ingresos por creación de mercado, al permitir coberturas más ajustadas y estrategias de arbitraje de volatilidad entre plazos, sino que fortalece la gestión de riesgo en tesorerías bancarias y mesas de derivados. En la práctica profesional, la construcción de la SVI suele abordarse mediante modelos paramétricos como Heston (1993) y SABR (Hagan et al., 2002), los cuales permiten calibrar superficies coherentes con los precios de opciones en un momento dado. No obstante, su aplicabilidad en mercados con datos dispersos o escasos es limitada, y su rigidez estructural puede generar errores sistemáticos en entornos de baja liquidez. Estas limitaciones motivan la exploración de enfoques estadísticos más flexibles, capaces de capturar la complejidad empírica de las SVI sin imponer supuestos restrictivos. Esta necesidad ha sido documentada en mercados emergentes como en China, donde Sui et al. (2020) evidencian que las SVI presentan dinámicas y patrones que divergen significativamente de los observados en economías desarrolladas, desafiando la validez de enfoques paramétricos tradicionales en mercados emergentes.

Frente a estas limitaciones, el análisis de datos funcionales (FDA) emerge como una alternativa robusta y flexible, capaz de capturar estructuras complejas y evolutivas como las SVI sin depender de supuestos paramétricos rígidos. Esta disciplina extiende los métodos estadísticos clásicos al análisis de objetos funcionales, como curvas o superficies, permitiendo describir su variabilidad y dinámica mediante herramientas de reducción de dimensión, suavizado y descomposición en componentes principales (Functional Principal Component Analysis, FPCA). El trabajo de Ramsay y Silverman (2006) constituye una referencia seminal en la formalización de estos métodos y su aplicación a problemas estadísticos complejos. Existen estudios previos que analizaron los factores latentes de las SVI, tanto mediante aproximaciones funcionales como en formulaciones multivariadas discretas, como Cont y Da Fonseca (2002) y Fengler et al. (2003). Posteriormente, Jaimungal y Ng (2007) formalizaron la aplicación de la FPCA a series financieras con muestreo irregular; un enfoque que fue ampliado por Grith et al. (2018), que aplican la FPCA directamente sobre superficies funcionales de densidad de precios Arrow–Debreu (derivadas de segundo orden de precios de opciones). Más recientemente,

diversos autores han empleado FPCA para el análisis y pronóstico de SVI en mercados desarrollados, como para opciones sobre acciones del S&P500 (Avellaneda et al., 2020) y pares de divisas del G10 (Kearney et al., 2018; Shang & Kearney, 2022; Weaver et al., 2020). Estos estudios refuerzan la utilidad del análisis funcional para capturar la dinámica empírica de la volatilidad en mercados líquidos y sirven de referencia metodológica para aplicaciones en mercados en desarrollo.

El desarrollo reciente de fuentes de datos densas y regulares, como las superficies diarias publicadas por Bloomberg desde febrero de 2025 para el par de divisas Dólar vs. Sol Peruano, presenta oportunidades para el estudio de la volatilidad implícita en mercados en desarrollo. En este nuevo contexto, la disponibilidad de mallas completas y uniformes en los ejes de delta y vencimiento permite modelar las SVI como superficies funcionales bidimensionales definidas sobre dominios densos, lo cual abre la puerta a enfoques basados en bases tensoriales B-spline. Estas bases fueron desarrolladas originalmente en el marco de los P-splines de Eilers y Marx (2003) y posteriormente formalizadas en contextos de modelos aditivos por Wood (2017). Su estructura se construye a partir del producto de Kronecker entre bases unidimensionales de cada eje (de Boor (2001) y Ruppert et al. (2003)), generando un espacio funcional bidimensional de soporte compacto y alta flexibilidad. Más recientemente, Reiss y Xu (2020) demostraron que las superficies tensoriales penalizadas ofrecen una representación explícita de los componentes principales funcionales, proporcionando un marco unificado para el suavizado y la descomposición espectral de covarianzas. Este enfoque permite controlar de manera explícita el grado de suavidad mediante la densidad y ubicación de los nodos, preservando la estabilidad numérica y la ortogonalidad de las funciones base mediante correcciones métricas derivadas de la matriz de Gram–Cholesky (Fahrmeir & Tutz, 2001; Ramsay & Silverman, 2006). En consecuencia, las bases tensoriales B-spline proporcionan un marco metodológico robusto para representar la variabilidad conjunta de las SVI a lo largo de sus dos dimensiones fundamentales: delta y tenor, facilitando su análisis y posterior descomposición funcional.

Por otro lado, el análisis dinámico de datos funcionales fue formalizado por Bosq (2000), quien introduce los procesos autorregresivos en espacios de Hilbert (ARH). Extiende las ecuaciones de Yule–Walker al dominio funcional y establece condiciones de consistencia bajo dependencia serial. Esto permite modelar directamente la evolución temporal de funciones completas en lugar de vectores de observaciones discretas. Bosq y Blanke (2007) extienden este marco a contextos de alta dimensión, explorando escenarios en que la representación funcional requiere truncamientos de base elevados. Mas y Pumo (2009) exploran la regresión funcional incorporando derivadas de primer y segundo orden como predictores, lo cual permite modelar interacciones más complejas entre curvas, aunque sin considerar dependencias temporales explícitas. Esta limitación es abordada por Aue et al. (2015), quienes proponen una teoría de predicción para series funcionales estacionarias, utilizando operadores de covarianza y

descomposiciones espectrales para estimar predictores lineales de mínima varianza. Tan et al. (2024) adoptan un enfoque secuencial, aplicando primero una FPCA clásica sobre SVI y modelando luego sus puntajes principales con un modelo VAR. Como alternativa a estos enfoques estructurados, Ferraty y Vieu (2006) ofrecen un modelo no paramétrico basado en regresión kernel, que evita suposiciones de linealidad o estacionariedad estricta y facilita la estimación de estructuras de dependencia no lineales. Un método similar fue aplicado recientemente por Liang et al. (2022) para modelar la volatilidad de activos financieros en contexto de alta frecuencia, empleando técnicas de suavizado y regresión funcional local sin asumir estructuras dinámicas explícitas. Por último, Ruiz-Medina et al. (2019) proponen un enfoque centrado en la estimación de operadores de autovalores y autocovarianza en el espacio de Hilbert en presencia de errores funcionales autocorrelacionados. El modelo combina regresores kernel con una estructura autorregresiva de tipo ARH(1) en los errores, integrando así relaciones no lineales entre funciones y dependencias dinámicas en un marco de regresión funcional.

En este contexto, la presente tesis propone un enfoque para representar y predecir superficies de volatilidad implícita en un mercado latinoamericano aprovechando la disponibilidad reciente de datos densos. El método integra tres bloques: (i) representación funcional de cada superficie mediante una base B-spline tensorial sobre los ejes de delta y tenor, con una corrección métrica para operar en el espacio L^2 ; (ii) reducción de dimensión mediante Análisis de Componentes Principales Funcional (FPCA), con el fin de extraer un conjunto parsimonioso de factores latentes que resumen la dinámica relevante de la SVI; y (iii) aplicación de un modelo predictivo en el espacio de puntajes de la FPCA, donde se comparan estrategias dinámicas de distinta complejidad (persistencia, VAR en puntajes, modelos autorregresivos tipo ARH sobre incrementos, y una variante no paramétrica basada en distancias tipo kernel), incorporando dependencia temporal remanente a través de una estructura autorregresiva de tipo ARH(1).

A diferencia de los enfoques que formulan la predicción directamente sobre objetos funcionales completos, esta tesis privilegia un flujo de trabajo unificado (representación $\rightarrow$ FPCA $\rightarrow$ regresión en puntajes) que mantiene la interpretación funcional de las superficies, pero reduce el problema de pronóstico a una dimensión baja donde la estimación fuera de muestra es más estable y el backtest (pruebas a fechas pasadas) es más transparente. La evaluación empírica se realiza mediante pronóstico móvil (rolling windows) y métricas sobre la malla fija, cuantificando tanto el error de representación (ajuste por base) como el desempeño fuera de muestra en distintos horizontes temporales.

1.1. Objetivos de la Tesis

El objetivo principal de esta tesis es representar y predecir las superficies de volatilidad implícita (SVI) de los mercados de opciones latinoamericanos mediante un modelo funcional integral que combina bases tensoriales B-spline, descomposición en componentes principales funcionales (FPCA) y regresión funcional con errores autorregresivos de tipo ARH(1). De manera específica:

- Revisar la literatura sobre análisis de datos funcionales, descomposición en componentes principales funcionales, suavizado mediante bases B-spline tensoriales, y modelos autorregresivos funcionales ARH(1) aplicados a series financieras.
- Construir una base de datos diaria de superficies de volatilidad implícita (SVI) para opciones de divisas en mercados latinoamericanos, a partir de información publicada por Bloomberg desde febrero de 2025.
- Representar las superficies de volatilidad implícita como funciones bidimensionales continuas sobre los ejes de delta y tenor, utilizando una base tensorial B-spline con corrección métrica mediante la matriz de Gram–Cholesky para preservar la ortogonalidad en el espacio $L^2(\delta, \tau)$.
- Aplicar la descomposición en componentes principales funcionales (FPCA) a la familia de superficies estimadas, y determinar el número óptimo de componentes a retener mediante criterios de varianza explicada y estabilidad espectral.
- Implementar y comparar modelos predictivos en el espacio de puntajes de la FPCA: persistencia, VAR en puntajes, modelos autorregresivos tipo ARH sobre incrementos y una alternativa no paramétrica basada en kernel, incorporando dependencia temporal mediante una estructura autorregresiva de tipo ARH(1).
- Validar el desempeño del modelo propuesto mediante procedimientos de validación cruzada y pronóstico móvil (rolling windows), evaluando métricas de error como RMSE y estabilidad de los componentes.
- Comparar la capacidad predictiva del modelo con enfoques de referencia, como el modelo funcional autorregresivo de vectores (FVAR) y el método ingenuo (naive), a fin de cuantificar su mejora relativa en precisión y estabilidad.

1.2. Organización del Trabajo

El capítulo 2 ofrece una síntesis de los conceptos y términos fundamentales relacionados a las opciones y SVI que son usados a lo largo de la tesis. En el capítulo 3, se revisan los

fundamentos teóricos del análisis de datos funcionales, la estimación de componentes principales funcionales, los modelos de regresión no paramétrica y los procesos autorregresivos en espacios de Hilbert. En el Capítulo 4, se desarrolla la representación funcional de las superficies de volatilidad implícita para los mercados latinoamericanos utilizando una base tensorial B-spline con corrección métrica mediante la matriz de Gram–Cholesky, y se determina el número óptimo de factores mediante FPCA. En el capítulo 5, se especifican y evalúan modelos de pronóstico en el espacio de puntajes de la FPCA bajo un diseño de validación fuera de muestra (rolling windows), comparando benchmarks de persistencia con alternativas lineales y no paramétricas, e incorporando dependencia temporal mediante una estructura autorregresiva de tipo ARH(1). Finalmente, el capítulo 7 presenta las conclusiones y recomendaciones para investigaciones futuras.

2. Conceptos básicos sobre opciones y superficies de volatilidad implícita

2.1. Opciones *vanilla*

- Opción call: Contrato que otorga al comprador el derecho, mas no la obligación, de comprar un activo subyacente a un precio de ejercicio R en la fecha de vencimiento T . Pago al vencimiento: $\max(S_T - R, 0)$.
- Opción put: Derecho a vender el subyacente a R en T . Pago: $\max(R - S_T, 0)$.
- Prima: Precio que el comprador paga hoy por adquirir la opción.
- Subyacente S : Activo respecto del cual se escribe la opción (acción, divisa, índice).
- Plazo o vencimiento T : Tiempo hasta la fecha de ejercicio; en la superficie se expresa como “time to maturity” (TTM).

2.2. Relación *moneyness*

La *moneyness* de una opción compara el strike R con el precio actual del subyacente S_0 :

- At-the-money (ATM): $R \approx S_0$.
- In-the-money (ITM): para opciones call $S_0 > R$; para opciones put $S_0 < R$.
- Out-of-the-money (OTM): para opciones call $S_0 < R$; para opciones put $S_0 > R$.

Conviene usar la *log-moneyness* $L = \log(R/S_0)$; así, $L = 0$ indica ATM, $L < 0$ indica opciones call ITM (y opciones put OTM), y $L > 0$ lo contrario.

2.3. Volatilidad implícita (VI)

Se denota como el parámetro σ que, introducido en la fórmula de Black-Scholes (u otro modelo de valoración), iguala el precio teórico al precio de mercado de la opción:

$$\text{Precio}_{\text{BS}}(S_0, R, T, \sigma) = \text{Precio}_{\text{mercado}}.$$

La VI resume la expectativa de volatilidad del mercado y permite comparar opciones con distintos R y T .

2.4. Superficie de volatilidad implícita (SVI)

Función bivariada $\sigma_{\text{imp}} : (R, T) \mapsto \sigma$, que asigna una volatilidad implícita (*imp*) a cada combinación de log-moneyness L y plazo T .

Tiene dos cortes que son usualmente estudiados:

- *Smile* de volatilidad: Se fija un vencimiento concreto $T = T_0$ y se grafica $\sigma_{\text{imp}}(L, T_0)$ frente al log-moneyness $L = \log(K/S_0)$. El resultado es la clásica “sonrisa” (*smile*) que muestra cómo la volatilidad implícita varía entre opciones ITM ($L < 0$), ATM ($L = 0$) y OTM ($L > 0$) para ese plazo específico. Sirve para evaluar la asimetría y la curvatura de la distribución implícita de retornos a corto, medio o largo plazo.
- Estructura temporal (*term structure*): Se fija $L = 0$ (ATM) y se traza $\sigma_{\text{imp}}(0, T)$ contra el tiempo a vencimiento T . Este corte revela cómo la volatilidad implícita evoluciona desde plazos cortos hasta largos, indicando si el mercado anticipa mayor incertidumbre a corto plazo (estructura descendente) o a largo plazo (estructura ascendente).

2.5. Patrones típicos

- *Skew*: asimetría entre colas; VI más alta para opciones put OTM que para opciones call OTM.
- *Smile*/curvatura: forma de “U”; mínima VI en ATM, mayor en colas (especialmente en plazos cortos)
- *Butterfly*: cambios en la convexidad de la smile; se observa al mover simultáneamente las VI de ambas colas.

Estos conceptos se emplearán para describir las componentes principales (resultados de la FPCA) y para interpretar los efectos estimados en los modelos de predicción.

3. Metodología

3.1. Análisis de Datos Funcionales (FDA)

El análisis de datos funcionales es un área de la estadística que aborda datos cuyas observaciones pueden representarse como funciones continuas en un dominio específico. A diferencia de los métodos multivariados tradicionales, donde las observaciones son vectores con dimensión fija, en FDA cada observación se modela como una función definida sobre un intervalo continuo (por ejemplo, tiempo o vencimiento). Este enfoque es especialmente útil cuando las observaciones están densamente medidas o pueden interpolarse con cierta precisión, y cuando se desea capturar propiedades como suavidad, derivabilidad, o dependencias estructurales internas. El trabajo de Ramsay y Silverman (2006) es seminal para la formalización de las técnicas de FDA y constituye la referencia principal de la presente sección.

Formalmente, se considera una variable aleatoria funcional $X(t)$ definida sobre un dominio continuo $t \in \mathcal{T} \subset \mathbb{R}$. Una muestra funcional consiste en n funciones observadas $X_i(t)_{i=1}^n$, cada una correspondiente a diferentes unidades o periodos de tiempo.

En la práctica, estas funciones rara vez se observan completamente. En cambio, se tiene acceso a observaciones discretas y ruidosas:

$$Y_{ij} = X_i(t_{ij}) + \varepsilon_{ij}, \quad j = 1, \dots, m_i,$$

donde ε_{ij} es un error de medición y los tiempos t_{ij} pueden variar entre unidades.

3.2. Espacio de Hilbert

Para formalizar el análisis de datos funcionales (FDA), es necesario definir el espacio matemático en el cual residen las observaciones funcionales (curvas, superficies o trayectorias). El marco natural para este propósito es el espacio de Hilbert, que generaliza las propiedades de los espacios euclidianos de dimensiones finitas a contextos infinitamente dimensionales.

Definición:

Sea $T \subseteq \mathbb{R}$ un dominio compacto (ej. tiempo hasta vencimiento, madurez o precio de ejercicio). Se define:

$$L^2(T) = \left\{ f : T \rightarrow \mathbb{R} \mid \int_T f(t)^2 dt < \infty \right\},$$

con producto interno y norma inducida:

$$\langle f, g \rangle = \int_T f(t)g(t) dt, \quad \|f\| = \sqrt{\langle f, f \rangle}.$$

Propiedades:

- **Completitud:** Toda sucesión de Cauchy $f_n \subseteq L^2(T)$ converge en norma a algún $f \in L^2(T)$. Esto garantiza que los límites de aproximaciones numéricas (ej. refinamiento de malla o aumento del orden de la base) permanecen dentro del espacio. Además, asegura la existencia de soluciones en problemas de minimización (ej. mínimos cuadrados penalizados).
- **Ortogonalidad y proyección:** Para un subespacio cerrado $V \subseteq L^2$ existe un proyector ortogonal $P_V : L^2 \rightarrow V$ único tal que $f - P_V f \perp V$ y $|f - P_V f| = \min_{v \in V} |f - v|$. Este resultado sustenta los mínimos cuadrados funcionales y la FPCA: proyectar sobre el subespacio generado por las autofunciones minimiza el error cuadrático.
- **Bases ortonormales y operadores de Hilbert–Schmidt:** Existen familias ortonormales φ_k densas en L^2 (teorema de Parseval). Los operadores lineales compactos con núcleo cuadrado-integrable son *Hilbert–Schmidt* (Bosq, 2000). Esto permite representar cualquier función como serie $\sum_k \xi_k \varphi_k$ y garantiza que el operador de covarianza de un proceso funcional posea espectro discreto, base de la expansión de Karhunen–Loève usada más adelante.
- **Teorema de representación de Riesz:** En todo espacio de Hilbert, incluido $L^2(T)$, cada funcional lineal y continuo $\ell : L^2 \rightarrow \mathbb{R}$ se expresa de forma única como producto interno: $\ell(f) = \langle f, g \rangle$ para algún $g \in L^2(T)$. Esto garantiza que cualquier evaluación lineal sobre funciones (ej. extracción de puntajes en FPCA, o coeficientes en la base B-spline) sea una operación continua y bien definida, incluso cuando los datos se observan con ruido o en mallas discretas.

Por ejemplo, sea $\sigma_{\text{imp}}(R, T)$ la volatilidad implícita para un strike R fijo en la madurez T . Fijando $T = T_0$, se obtiene:

$$R \mapsto \sigma_{\text{imp}}(R, T_0) \in L^2([R_{\text{mín}}, R_{\text{máx}}])$$

Cada fecha de negociación aporta una realización funcional (ej. la SVI $R \mapsto \sigma_{imp}(R, T_0)$ sobre un intervalo compacto de strikes). El conjunto completo se modela como una muestra i.i.d. en L^2 .

De esta forma, es posible representar funciones mediante combinaciones finitas de funciones base, lo cual facilita tanto la aproximación numérica como la estimación estadística de los objetos funcionales.

3.3. Aproximación funcional mediante bases B-spline

Para representar funciones cuadrado-integrables en un dominio compacto $T = [a, b] \subset \mathbb{R}$ se empleará una base B-spline, por su estabilidad numérica, soporte local y control explícito de suavidad (de Boor, 2001; Ramsay & Silverman, 2006; Ruppert et al., 2003).

Definición (Cox–de Boor):

Sea un vector de nodos no decreciente $\boldsymbol{\tau} = (\tau_0, \dots, \tau_M)$ con $\tau_0 = a$ y $\tau_M = b$. Fijado el grado $p \geq 1$ (orden $p + 1$), las B-splines $\{B_{k,p}\}_{k=1}^K$, con

$$K = M + p - 1,$$

se definen recursivamente por

$$B_{k,0}(t) = \begin{cases} 1, & \tau_{k-1} \leq t < \tau_k, \\ 0, & \text{en otro caso,} \end{cases}$$

$$B_{k,p}(t) = \frac{t - \tau_{k-1}}{\tau_{k+p-1} - \tau_{k-1}} B_{k,p-1}(t) + \frac{\tau_{k+p} - t}{\tau_{k+p} - \tau_k} B_{k+1,p-1}(t).$$

Cada $B_{k,p}$ es un polinomio por tramos de grado p con soporte local $[\tau_{k-1}, \tau_{k+p}]$ y satisface partición de la unidad: $\sum_{k=1}^K B_{k,p}(t) = 1$ para todo $t \in [a, b]$. Toda $f \in L^2([a, b])$ suficientemente regular se aproxima como

$$f(t) \approx \sum_{k=1}^K c_k B_{k,p}(t), \quad \mathbf{c} = (c_1, \dots, c_K)^\top.$$

Propiedades:

- Soporte local y dispersión: c_k solo afecta a f en $[\tau_{k-1}, \tau_{k+p}]$. La matriz de diseño $\mathbf{B} \in \mathbb{R}^{n \times K}$, con elementos $\mathbf{B}_{ik} = B_{k,p}(t_i)$, es dispersa y de banda limitada (ancho $\approx 2p + 1$), lo que mejora el condicionamiento numérico.
- Suavidad controlable: con nodos simples, $B_{k,p} \in C^{p-1}$; nodos repetidos reducen continuidad en el punto. En la práctica, cúbicas ($p = 3$) equilibran flexibilidad y estabilidad.

- Invarianza de escala local: se adaptan bien a reparametrizaciones suaves (por ejemplo, transformaciones de tenor en logaritmos), que permiten colocar nodos donde la función cambia más rápido.

Estimación:

Dados datos ruidosos $\mathbf{y} = (y_1, \dots, y_n)^\top$ en puntos $\mathbf{t} = (t_1, \dots, t_n)$, con matriz de diseño $\mathbf{B}_{ik} = B_{k,p}(t_i)$, la estimación por mínimos cuadrados es

$$\hat{\mathbf{c}}_{\text{LS}} = \arg \min_{\mathbf{c}} \|\mathbf{y} - \mathbf{B}\mathbf{c}\|^2 = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{y}.$$

Para controlar la suavidad global se usa la versión penalizada

$$\hat{\mathbf{c}}_\lambda = \arg \min_{\mathbf{c}} \|\mathbf{y} - \mathbf{B}\mathbf{c}\|^2 + \lambda \mathbf{c}^\top \mathbf{P} \mathbf{c},$$

donde $\mathbf{P}$ implementa una penalización de curvatura

$$\int_a^b (f^{(m)}(t))^2 dt$$

(expresada en la base $B_{k,p}$), típicamente con $m = 2$ (Ramsay & Silverman, 2006; Ruppert et al., 2003). Este esquema penalizado se generaliza naturalmente al caso bidimensional mediante productos tensoriales, donde Reiss y Xu (2020) demostraron que la forma de la penalización influye directamente en los autovalores y autovectores obtenidos en el análisis de componentes principales funcionales, proporcionando un marco unificado para el suavizado y la descomposición espectral. El parámetro $\lambda \geq 0$ regula el compromiso sesgo-varianza: $\lambda \rightarrow 0$ tiende a interpolar; $\lambda \rightarrow \infty$ fuerza soluciones muy lisas.

Métrica funcional:

La matriz de Gram $G \in \mathbb{R}^{K \times K}$,

$$G_{kl} = \int_a^b B_{k,p}(t) B_{l,p}(t) dt,$$

induce el producto interno $\langle f, g \rangle = \mathbf{c}_f^\top G \mathbf{c}_g$ en el subespacio generado por la base. Esta métrica será esencial para corregir la PCA euclídeana en coeficientes y operar en el espacio funcional L^2 (secciones de producto tensorial y FPCA).

Elección de hiperparámetros:

- Grado: $p = 3$ por defecto (continuidad C^2 con nodos simples).
- Ubicación y número de nodos: más densos donde la función varía rápido; más espaciados en regiones lisas. Se puede aplicar como criterio el equiespaciado en una escala transformada (p. ej., log-tenor) o por cuantiles (Ruppert et al., 2003).

- Penalización: selección por GCV, BIC, o validación sobre ventanas, cuando se emplea penalización global (Ramsay & Silverman, 2006).

Esta sección describe la base unidimensional. A continuación se construirá la base bidimensional para superficies $f(\delta, \tau)$ mediante producto tensorial de dos bases B-spline, y se introducirá la corrección métrica de Gram–Cholesky y el diseño de Kronecker que se usarán en el resto de la tesis.

3.4. Base tensorial B-spline para superficies bidimensionales

Esta sección formaliza la representación de superficies de volatilidad implícita como funciones en dos variables $f(\delta, \tau)$ mediante una base B-spline tensorial. El objetivo es obtener una parametrización flexible, estable y con métrica funcional explícita para su posterior descomposición en componentes principales.

Dominios y bases unidimensionales:

Sea $\Delta = [\delta_{\min}, \delta_{\max}] \subset \mathbb{R}$ el dominio de moneyness (o delta) y $T = [\tau_{\min}, \tau_{\max}] \subset \mathbb{R}$ el dominio de tenor. Se fijan dos bases B-spline unidimensionales:

$$\{B_i^{(\delta)}(\delta)\}_{i=1}^{K_\delta}, \quad \{B_j^{(\tau)}(\tau)\}_{j=1}^{K_\tau},$$

con grados cúbicos y vectores de nodos posiblemente distintos en cada eje (de Boor, 2001; Ramsay & Silverman, 2006; Ruppert et al., 2003). Se denota por $\Phi_\delta \in \mathbb{R}^{n_\delta \times K_\delta}$ y $\Phi_\tau \in \mathbb{R}^{n_\tau \times K_\tau}$ las matrices de diseño que evalúan estas bases en las mallas de observación

$$\boldsymbol{\delta} = (\delta_1, \dots, \delta_{n_\delta})^\top, \quad \boldsymbol{\tau} = (\tau_1, \dots, \tau_{n_\tau})^\top,$$

es decir, $(\Phi_\delta)_{ui} = B_i^{(\delta)}(\delta_u)$ y $(\Phi_\tau)_{vj} = B_j^{(\tau)}(\tau_v)$.

Producto tensorial y vectorización:

La base bidimensional se construye como productos

$$\left\{ B_i^{(\delta)}(\delta) B_j^{(\tau)}(\tau) \right\}_{i=1, \dots, K_\delta; j=1, \dots, K_\tau}.$$

Cualquier superficie suficientemente regular $f \in L^2(\Delta \times T)$ se aproxima por

$$f(\delta, \tau) \approx \sum_{i=1}^{K_\delta} \sum_{j=1}^{K_\tau} c_{ij} B_i^{(\delta)}(\delta) B_j^{(\tau)}(\tau),$$

con coeficientes c_{ij} desconocidos. En la malla rectangular $\{(\delta_u, \tau_v)\}$, la matriz de valores $F \in \mathbb{R}^{n_\delta \times n_\tau}$ tiene elementos $F_{uv} = f(\delta_u, \tau_v)$ y se factoriza como

$$F \approx \Phi_\delta C \Phi_\tau^\top, \quad C \in \mathbb{R}^{K_\delta \times K_\tau}, \quad (C)_{ij} = c_{ij}.$$

Al apilar por columnas con $\text{vec}(F) \in \mathbb{R}^{n_\delta n_\tau}$ y $\text{vec}(C) \in \mathbb{R}^{K_\delta K_\tau}$, se obtiene la forma lineal

$$\mathbf{y} = \text{vec}(F) \approx X \mathbf{c}, \quad X = \Phi_\tau \otimes \Phi_\delta \in \mathbb{R}^{(n_\delta n_\tau) \times (K_\delta K_\tau)}, \quad \mathbf{c} = \text{vec}(C).$$

Aquí, $\otimes$ denota el producto de Kronecker. Esta identidad es estándar en modelos aditivos y superficies tensoriales (Wood, 2017).

Estimación mediante mínimos cuadrados por día:

Dado un día t con observaciones ruidosas $y_{uv}^{(t)} \approx f_t(\delta_u, \tau_v)$, apiladas en $\mathbf{y}^{(t)} = \text{vec}(F^{(t)})$, se estiman los coeficientes tensoriales por mínimos cuadrados

$$\hat{\mathbf{c}}^{(t)} = \arg \min_{\mathbf{c}} \|\mathbf{y}^{(t)} - X \mathbf{c}\|^2 = (X^\top X)^{-1} X^\top \mathbf{y}^{(t)}.$$

Si existen celdas ausentes, se define un vector $\mathbf{m}^{(t)} \in \{0, 1\}^{n_\delta n_\tau}$ y se restringe a las filas observadas: $X^{(t)} = X[\mathbf{m}^{(t)} = 1, \cdot]$, $\mathbf{y}^{(t)} = \mathbf{y}^{(t)}[\mathbf{m}^{(t)} = 1]$, lo que da

$$\hat{\mathbf{c}}^{(t)} = ((X^{(t)})^\top X^{(t)})^{-1} (X^{(t)})^\top \mathbf{y}^{(t)}.$$

En el caso homogéneo (misma malla todos los días), X se precalcula una vez; el término normal $(X^\top X)^{-1} X^\top$ se reutiliza para todos los t .

Métrica funcional y corrección Gram–Cholesky:

El espacio $L^2(\Delta \times T)$ induce el producto interno

$$\langle f, g \rangle = \int_{\Delta} \int_T f(\delta, \tau) g(\delta, \tau) d\tau d\delta.$$

En coordenadas de la base tensorial, la métrica está dada por la matriz de Gram

$$G = G_\tau \otimes G_\delta, \quad (G_\delta)_{ii'} = \int_{\Delta} B_i^{(\delta)}(\delta) B_{i'}^{(\delta)}(\delta) d\delta, \quad (G_\tau)_{jj'} = \int_T B_j^{(\tau)}(\tau) B_{j'}^{(\tau)}(\tau) d\tau,$$

de modo que $\langle f, g \rangle = \mathbf{c}_f^\top G \mathbf{c}_g$ (Ramsay & Silverman, 2006). Para realizar PCA en el espacio funcional y no en el espacio euclidiano de coeficientes, se utiliza la factorización de Cholesky

$$G = S^\top S.$$

Con coeficientes centrados $\tilde{\mathbf{c}}^{(t)} = \hat{\mathbf{c}}^{(t)} - \bar{\mathbf{c}}$, donde $\bar{\mathbf{c}}$ es la media temporal, se define la transformación estandarizada respecto de la métrica L^2 ,

$$\mathbf{u}^{(t)} = S \tilde{\mathbf{c}}^{(t)} \in \mathbb{R}^{K_\delta K_\tau}.$$

la cual es una isometría inducida por la factorización de Cholesky $G = S^\top S$ del operador de Gram.

La PCA euclidiana sobre $\{\mathbf{u}^{(t)}\}_t$ es algebraicamente equivalente a una FPCA con la métrica $L^2(\Delta \times T)$. Si $\mathbf{w}_k$ denota el k -ésimo autovector obtenido en el espacio transformado $\{\mathbf{u}^{(t)}\}$, los eigenvectores en el espacio de coeficientes se recuperan como

$$\mathbf{v}_k = S^{-1} \mathbf{w}_k, \quad \|\mathbf{v}_k\|_G^2 = \mathbf{v}_k^\top G \mathbf{v}_k = 1,$$

donde $G = S^\top S$ es la matriz de Gram. Esta corrección evita sesgos debidos a bases no ortonormales.

Reconstrucción y evaluación:

Para visualizar o evaluar superficies, se construyen matrices de diseño Φ_δ^* y Φ_τ^* en rejillas densas; el diseño tensorial es

$$X^* = \Phi_\tau^* \otimes \Phi_\delta^*.$$

La superficie media y las deformaciones según componentes principales (escala ± 1 desviación estándar en el espacio blanqueado) se obtienen como

$$\hat{\mathbf{f}}_{\text{media}}^* = X^* \bar{\mathbf{c}}, \quad \hat{\mathbf{f}}_{\text{media} \pm k}^* = X^* (\bar{\mathbf{c}} \pm \mathbf{v}_k \sigma_k),$$

donde σ_k es la desviación estándar de los puntajes $t \mapsto \mathbf{w}_k^\top \mathbf{u}^{(t)}$.

Diagnósticos y criterios de especificación:

- PRESS (Prediction Error Sum of Squares) y matriz sombrero: En el caso homogéneo, $H = X(X^\top X)^{-1}X^\top$. La aproximación leave-one-out (LOO) del residuo en el punto i es $e_i^{\text{LOO}} = e_i / (1 - h_{ii})$, donde e_i es el residuo ordinario y h_{ii} la i -ésima diagonal de H .

$$\text{PRESS} = \sum_i \left(\frac{e_i}{1 - h_{ii}} \right)^2.$$

Así, medianas y percentiles del RMSE derivado de e_i^{LOO} se utilizan para comparar especificaciones y guiar la elección de K_δ, K_τ .

- Apalancamientos: h_{ii} cercanos a 1 indican interpolación local; su concentración por región (alas o tenores cortos) sugiere incrementar flexibilidad en el eje correspondiente.
- Residuos por celda: Mapas de calor de $F - \hat{F}$ por (δ, τ) permiten detectar falta de ajuste sistemática en alas o bordes (motiva reubicar nodos).
- Sensibilidad de subespacios: Distancias entre proyecciones de subespacios $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_K\}$ bajo pequeñas variaciones en K_δ, K_τ sirven para evaluar estabilidad de las direcciones principales.

Aspectos numéricos y convenciones.

- Orden de apilado: Se adopta $\mathbf{y} = \text{vec}(F)$ con tenor variando más rápido (column-major); en esta convención $X = \Phi_\tau \otimes \Phi_\delta$.
- Condición de rango: Es necesario $\text{rank}(X) = K_\delta K_\tau$ (o de $X^{(t)}$ por día) para identificar $\mathbf{c}$. Elegir K_δ, K_τ con margen respecto a n_δ, n_τ y evitar bases excesivas.

- Gram y cuadraturas: G_δ y G_τ se evalúan por integración exacta de B-splines o cuadraturas (Gauss–Legendre) suficientemente finas; $G = G_\tau \otimes G_\delta$ y $S = \text{chol}(G)$ han de ser bien condicionadas (de Boor, 2001; Ramsay & Silverman, 2006).
- Bordes: Colocar nodos externos repetidos (orden $p + 1$) mejora estabilidad en extremos y reduce artefactos de extrapolación.

3.5. Descomposición en Componentes Principales Funcionales (FPCA) sobre superficies bidimensionales

Esta sección desarrolla la FPCA cuando cada observación diaria es una superficie escalar $X(\delta, \tau) \in L^2(\Delta \times T)$ y su representación numérica se ha obtenido mediante una base B-spline tensorial. Denote por

$$\hat{X}^{(t)}(\delta, \tau) = \sum_{k=1}^K \hat{c}_k^{(t)} \Psi_k(\delta, \tau), \quad K = K_\delta K_\tau,$$

la aproximación de la superficie del día t en la base producto $\{\Psi_k\}$, con vector de coeficientes $\hat{\mathbf{c}}^{(t)} = (\hat{c}_1^{(t)}, \dots, \hat{c}_K^{(t)})^\top$.

Métrica funcional y centrado:

Sea $G \in \mathbb{R}^{K \times K}$ la matriz de Gram de la base producto,

$$G_{kl} = \iint_{\Delta \times T} \Psi_k(\delta, \tau) \Psi_l(\delta, \tau) d\delta d\tau, \quad G = S^\top S \text{ (descomposición de Cholesky).}$$

La media funcional estimada en coeficientes es

$$\bar{\mathbf{c}} = \frac{1}{n} \sum_{t=1}^n \hat{\mathbf{c}}^{(t)}, \quad \tilde{\mathbf{c}}^{(t)} = \hat{\mathbf{c}}^{(t)} - \bar{\mathbf{c}}.$$

El producto interno inducido por G cumple $\langle f, g \rangle = \mathbf{c}_f^\top G \mathbf{c}_g$ y $\|f\|^2 = \mathbf{c}_f^\top G \mathbf{c}_f$ en el subespacio generado por la base.

PCA en la métrica $L^2(\Delta \times T)$:

Existen dos formulaciones equivalentes (Ramsay & Silverman, 2006):

- Problema de autovalores generalizado: Sea la covarianza muestral en coeficientes $\Sigma = \frac{1}{n} \sum_{t=1}^n \tilde{\mathbf{c}}^{(t)} \tilde{\mathbf{c}}^{(t)\top}$. Las componentes principales funcionales resuelven

$$\Sigma \mathbf{v}_k = \lambda_k G \mathbf{v}_k, \quad \mathbf{v}_k^\top G \mathbf{v}_\ell = \mathbb{I}\{k = \ell\},$$

dando autovalores λ_k (varianza explicada) y autovectores $\mathbf{v}_k$ que representan las autofunciones $\Phi_k(\delta, \tau) = \sum_{j=1}^K v_{k,j} \Psi_j(\delta, \tau)$ normalizadas en $L^2(\Delta \times T)$.

- Transformación mediante Cholesky: Defina la transformación lineal $\mathbf{u}^{(t)} = S \tilde{\mathbf{c}}^{(t)}$ y la matriz de covarianza transformada $\Sigma_u = \frac{1}{n} \sum_{t=1}^n \mathbf{u}^{(t)} \mathbf{u}^{(t)\top}$. La PCA euclidiana de $\{\mathbf{u}^{(t)}\}$ produce autovectores $\mathbf{w}_k$ y autovalores λ_k . Los autovectores en el espacio de coeficientes se recuperan como

$$\mathbf{v}_k = S^{-1} \mathbf{w}_k, \quad \|\mathbf{v}_k\|_G^2 = \mathbf{v}_k^\top G \mathbf{v}_k = 1,$$

y las autofunciones Φ_k se obtienen como arriba.

Ambas formulaciones son algebraicamente idénticas: la segunda reduce el problema generalizado al caso euclídeo vía la métrica de Gram y suele ser más estable numéricamente con bases no ortonormales (Ramsay & Silverman, 2006).

Puntajes funcionales y reconstrucción:

Los puntajes principales del día t se calculan como proyecciones en la métrica G :

$$\xi_k^{(t)} = \langle \tilde{X}^{(t)}, \Phi_k \rangle = \tilde{\mathbf{c}}^{(t)\top} G \mathbf{v}_k = \mathbf{u}^{(t)\top} \mathbf{w}_k.$$

La aproximación de rango K_0 de la superficie es

$$\hat{X}_{(K_0)}^{(t)}(\delta, \tau) = \bar{X}(\delta, \tau) + \sum_{k=1}^{K_0} \xi_k^{(t)} \Phi_k(\delta, \tau), \quad \bar{X}(\delta, \tau) = \sum_{j=1}^K \bar{c}_j \Psi_j(\delta, \tau).$$

El error de truncamiento en norma $L^2(\Delta \times T)$ está acotado por $\sum_{k > K_0} \lambda_k$.

Algoritmo de estimación:

- Obtener $\tilde{\mathbf{c}}^{(t)}$ por mínimos cuadrados en la base tensorial y centrar: $\tilde{\mathbf{c}}^{(t)}$.
- Construir $G = G_\tau \otimes G_\delta$ y su Cholesky $G = S^\top S$.
- Formar $\mathbf{u}^{(t)} = S \tilde{\mathbf{c}}^{(t)}$ y aplicar PCA euclidiana a la matriz de datos transformados (filas = días, columnas = K).
- Mapear autovectores: $\mathbf{v}_k = S^{-1} \mathbf{w}_k$ y normalizar en G .
- Calcular puntajes: $\xi_k^{(t)} = \mathbf{u}^{(t)\top} \mathbf{w}_k$; reconstruir con K_0 componentes.

Selección del número de componentes K_0 :

Se consideran criterios complementarios (Ramsay & Silverman, 2006):

- Porcentaje de varianza explicada (FVE): elegir el menor K_0 tal que $\sum_{k=1}^{K_0} \lambda_k / \sum_{k=1}^K \lambda_k \geq \alpha$ (típicamente $\alpha \in [0,95, 0,99]$).

- Criterio BIC penalizado sobre K_0 : $\text{BIC}(K_0) = n \log(\text{RSS}_{K_0}/n) + K_0 \log n$, donde RSS_{K_0} es la suma de errores de reconstrucción en norma L^2 .
- Pruebas de corte (bootstrap): contrastar $H_0 : \lambda_{K_0+1} = 0$ vía remuestreo de residuos en el espacio de coeficientes.

Diagnósticos metodológicos:

Para validar la base tensorial y la elección de K_δ, K_τ antes de fijar K_0 :

- Error de reconstrucción y PRESS (Predicted Residual Sum of Squares) con matriz sombrero $H = X(X^\top X)^{-1}X^\top$ en el ajuste por día; usar $e_i/(1 - h_{ii})$ como aproximación leave-one-out.
- Leverage h_{ii} por nodo de la malla; valores cercanos a 1 indican interpolación excesiva.
- Estructura de residuos $V - \hat{V}$ por (δ, τ) para detectar rigidez en alas o vencimientos cortos.
- Estabilidad de subespacios: distancia de proyección entre las envolventes de $\{\Phi_1, \Phi_2, \Phi_3\}$ al variar (K_δ, K_τ) en submuestras temporales.

Interpretación en SVI:

En aplicaciones a superficies de volatilidad implícita, es habitual que las primeras componentes se interpreten como: (i) nivel global de la superficie; (ii) inclinación o skew entre puts OTM y calls OTM; (iii) curvatura o efecto de alas. Esta estructura de factores ha sido documentada repetidamente en datos de índices y divisas (Cont & Da Fonseca, 2002; Fengler et al., 2003).

3.6. Regresión kernel en puntajes FPCA con errores ARH(1)

El punto de partida conceptual es el marco de regresión funcional dinámica con errores ARH(1) estudiado por Ruiz-Medina et al. (2019). En su formulación general, la respuesta funcional $Y_t \in H$ (con H un espacio de Hilbert real separable) se modela como

$$Y_t = \mu_t + \varepsilon_t, \quad \varepsilon_{t+1} = \rho_H(\varepsilon_t) + \delta_{t+1},$$

donde μ_t representa la media condicional (potencialmente dependiente de información previa y/o regresores funcionales), $\rho_H : H \rightarrow H$ es un operador lineal de autocorrelación y $\{\delta_t\}$ es ruido blanco en H (media cero, sin correlación serial).

En esta tesis, el objeto observado en cada fecha es una superficie diaria $Y_t(\delta, \tau) \in L^2(\Delta \times T)$. Las Secciones 3.2–3.5 establecen una representación funcional estable y una reducción de dimensión mediante FPCA con métrica correcta. El resultado operativo de ese bloque es:

- un vector de *puntajes* FPCA truncados

$$Z_t = (\xi_{t,1}, \dots, \xi_{t,K_0})^\top \in \mathbb{R}^{K_0}, \quad (1)$$

que resume la superficie diaria en K_0 coordenadas ortogonales respecto de la métrica funcional;

- un operador de reconstrucción (definido en 3.5) que mapea puntajes a una superficie en la malla de evaluación,

$$z \mapsto \hat{y}(z) \in \mathbb{R}^n, \quad (2)$$

de modo que la predicción de superficies se reduce a la predicción de puntajes seguida de reconstrucción.

Bajo esta parametrización, el modelo dinámico se plantea directamente en el espacio reducido $\mathbb{R}^{K_0}$, preservando la idea central del enfoque ARH(1): una estructura explícita de dependencia temporal en el componente residual.

Descomposición dinámica en media condicional y residuo

La dinámica de los puntajes se expresa mediante una descomposición en un componente sistemático y un residuo:

$$Z_{t+1} = m(Z_t) + e_{t+1}. \quad (3)$$

Aquí $m : \mathbb{R}^{K_0} \rightarrow \mathbb{R}^{K_0}$ representa la media condicional de Z_{t+1} dado Z_t . Es decir,

$$m(z) = E[Z_{t+1} \mid Z_t = z].$$

El término e_{t+1} corresponde al residuo no explicado por esa media condicional:

$$e_{t+1} = Z_{t+1} - m(Z_t).$$

Por construcción, el residuo tiene media cero condicional a Z_t , esto es, $E[e_{t+1} \mid Z_t] = 0$.

Incluso si $m(\cdot)$ captura relaciones no lineales relevantes, en series financieras es habitual que persista memoria temporal en los residuos. Para modelar esa persistencia, se adopta una estructura ARH(1) en dimensión finita:

$$e_{t+1} = \rho e_t + u_{t+1}, \quad E[u_{t+1} \mid \mathcal{F}_t] = 0, \quad (4)$$

donde $\rho \in \mathbb{R}^{K_0 \times K_0}$ y $\{u_t\}$ es ruido blanco vectorial (media cero y sin correlación serial). Una condición suficiente de estabilidad es que el radio espectral cumpla con

$$r(\rho) < 1 \quad (\text{equivalentemente, } \max_j |\lambda_j(\rho)| < 1), \quad (5)$$

lo que garantiza una dinámica residual estable.

Estimación no paramétrica de la media condicional

La media condicional $m(\cdot)$ se estima mediante un suavizador por núcleo del tipo Nadaraya–Watson. Dada una muestra de puntajes $\{Z_1, \dots, Z_T\}$, para un instante t (con $2 \leq t \leq T-1$) se utiliza el conjunto de pares disponibles $\{(Z_i, Z_{i+1})\}_{i=1}^{t-1}$ y se define

$$\hat{m}_t(z) = \frac{\sum_{i=1}^{t-1} w_i(z) Z_{i+1}}{\sum_{i=1}^{t-1} w_i(z)}, \quad w_i(z) = K\left(\frac{d(z, Z_i)}{h}\right), \quad (6)$$

donde:

- $K(\cdot)$ es un núcleo radial no negativo (por ejemplo, el núcleo gaussiano $K(u) = \exp(-u^2/2)$);
- $h > 0$ es el ancho de banda;
- $d(\cdot, \cdot)$ es una distancia en $\mathbb{R}^{K_0}$.

Distancia estandarizada. Como los componentes de Z_t pueden presentar escalas distintas, la distancia se evalúa en coordenadas estandarizadas:

$$d(z, z') = \|D^{-1}(z - z')\|_2, \quad D = \text{diag}(s_1, \dots, s_{K_0}), \quad (7)$$

donde s_ℓ es la desviación estándar muestral del componente ℓ . Este escalamiento evita que uno o pocos puntajes dominen los pesos del núcleo.

Residuos y estimación del operador ARH(1)

Una vez estimada la media condicional, los residuos empíricos se obtienen como

$$\hat{e}_{t+1} = Z_{t+1} - \hat{m}_t(Z_t), \quad (8)$$

para los instantes donde la estimación esté bien definida (típicamente $t = 1, \dots, T-1$).

El operador ρ se estima mediante un análogo vectorial de las ecuaciones de Yule-Walker o, equivalentemente, por mínimos cuadrados, con regularización tipo ridge para estabilizar la

inversión. Sea $T' = T - 2$ el número de pares consecutivos disponibles para el ajuste AR(1) en residuos. Se definen

$$\hat{C}_0 = \frac{1}{T'} \sum_{t=1}^{T'} \hat{e}_t \hat{e}_t^\top, \quad \hat{C}_1 = \frac{1}{T'} \sum_{t=1}^{T'} \hat{e}_{t+1} \hat{e}_t^\top, \quad (9)$$

y el estimador regularizado

$$\hat{\rho} = \hat{C}_1 (\hat{C}_0 + \lambda_\rho I_{K_0})^{-1}, \quad \lambda_\rho > 0. \quad (10)$$

La penalización λ_ρ reduce inestabilidades numéricas cuando K_0 no es pequeño o cuando $\hat{C}_0$ es mal condicionada.

Predicción de puntajes y reconstrucción de superficies

Predicción a un horizonte de un período. La predicción condicional de los puntajes (un período adelante) se define como el valor esperado condicional bajo el modelo (3)–(4):

$$\hat{Z}_{t+1|t} = \hat{m}_t(Z_t) + \hat{\rho} \hat{e}_t, \quad \hat{e}_t = Z_t - \hat{m}_{t-1}(Z_{t-1}), \quad (11)$$

para $t \geq 2$.

Luego, la predicción de la superficie en malla se obtiene aplicando el operador de reconstrucción (14):

$$\hat{y}_{t+1|t} = \hat{y}(\hat{Z}_{t+1|t}) \in \mathbb{R}^n. \quad (12)$$

Predicción a horizonte $h > 1$. Para un horizonte $h > 1$, la iteración se realiza propagando el estado predicho y la componente residual según su esperanza condicional. En particular, se utiliza la recursión

$$\begin{aligned} \hat{e}_{t+1|t} &= \hat{\rho} \hat{e}_t, \\ \hat{e}_{t+k|t} &= \hat{\rho} \hat{e}_{t+k-1|t} = \hat{\rho}^k \hat{e}_t, \quad k = 2, \dots, h, \end{aligned}$$

y se define

$$\hat{Z}_{t+k|t} = \hat{m}_t(\hat{Z}_{t+k-1|t}) + \hat{e}_{t+k|t}, \quad k = 1, \dots, h.$$

La predicción de la superficie al horizonte h resulta de

$$\hat{y}_{t+h|t} = \hat{y}(\hat{Z}_{t+h|t}).$$

Este esquema es consistente con la estructura AR(1) adoptada para los residuos y permite generar trayectorias predichas en el espacio reducido.

5. Enlace con ARH(1) funcional tras truncación FPCA

El uso de un residuo con dependencia ARH(1) en $\mathbb{R}^{K_0}$ se justifica como una operacionalización de la idea funcional de Ruiz-Medina et al. (2019). Si $\varepsilon_t \in H$ satisface $\varepsilon_{t+1} = \rho_H(\varepsilon_t) + \delta_{t+1}$ y P_{K_0} es el proyector ortogonal sobre el subespacio generado por las primeras K_0 autofunciones FPCA (ortonormales en la métrica correcta), entonces el residuo proyectado $P_{K_0}\varepsilon_t$ pertenece a un subespacio de dimensión finita. Bajo una aproximación de truncación del operador

$$\rho_H \approx P_{K_0}\rho_H P_{K_0},$$

la dinámica proyectada se aproxima por un AR(1) vectorial en coordenadas de puntajes, lo que conduce al modelo (4). En consecuencia, el término $\hat{\rho}\hat{\varepsilon}_t$ de (11) preserva la interpretación de *memoria residual* propia del marco ARH(1), pero en un espacio reducido y numéricamente estable.

En síntesis, el procedimiento integra tres piezas coherentes entre sí: (i) FPCA con métrica funcional correcta (estado reducido Z_t), (ii) estimación no paramétrica de la media condicional por suavización con núcleo ($\hat{m}_t$), y (iii) dependencia temporal explícita en residuos mediante ARH(1) truncado ($\hat{\rho}$). Esta combinación define el modelo principal evaluado empíricamente en la Sección 5.

3.7. Modelos de referencia

El modelo propuesto en la sección anterior se compara con un conjunto de modelos de referencia que cubren, de forma escalonada, cuatro ideas básicas en este problema:

- **Persistencia en la malla observada** (referencia mínima).
- **Persistencia del componente ajustado** (separa ruido de medición vs dinámica).
- **Modelos lineales en el espacio de puntajes** (dinámica lineal multivariante).
- **Dependencia ARH(1) en puntajes sin regresión por núcleo** (aísla el efecto del núcleo).

En todos los casos, el objetivo es pronosticar la superficie futura Y_{t+h} en la malla (δ_r, τ_s) y medir el error fuera de muestra. Sea $y_t \in \mathbb{R}^n$ el vector de observaciones en la malla en la fecha t , con $n = n_\delta n_\tau$. Sea $\hat{c}_t \in \mathbb{R}^p$ el vector de coeficientes de la base tensorial estimado en las Secciones 3.3–3.4. La superficie *ajustada por base* queda representada por

$$\hat{y}_t^{\text{aj}} = X \hat{c}_t \in \mathbb{R}^n. \quad (13)$$

Asimismo, sea $Z_t \in \mathbb{R}^{K_0}$ el vector de puntajes FPCA (Sección 3.5) y sea $\hat{y}(\cdot)$ el operador de reconstrucción que transforma puntajes en superficies en la malla (Sección 3.5),

$$\hat{y}(z) = X(\bar{c} + S^{-\top}Az) \in \mathbb{R}^n. \quad (14)$$

3.7.1. Persistencia en la malla observada (PM)

El modelo más simple asume que la superficie observada no cambia:

$$\hat{y}_{t+h|t}^{\text{PM}} = y_t, \quad h \geq 1. \quad (15)$$

Esta referencia es deliberadamente elemental, pero indispensable en series con alta persistencia a horizontes cortos.

3.7.2. Persistencia de la superficie ajustada (PA)

Como y_t puede contener ruido de medición, valores faltantes e irregularidades de malla, se utiliza una segunda referencia que persiste la superficie ajustada por base:

$$\hat{y}_{t+h|t}^{\text{PA}} = \hat{y}_t^{\text{aj}} = X\hat{c}_t, \quad h \geq 1. \quad (16)$$

Este modelo separa la contribución de *estabilizar la representación funcional* de la contribución de *modelar dinámica temporal*.

3.7.3. Autorregresivo vectorial de orden 1 en puntajes (VAR(1))

Al proyectar las superficies al espacio reducido $Z_t \in \mathbb{R}^{K_0}$, la dinámica se aproxima mediante un modelo lineal multivariante:

$$Z_{t+1} = a + BZ_t + \eta_{t+1}, \quad E[\eta_{t+1}] = 0, \quad \text{Cov}(\eta_{t+1}) = \Sigma_\eta, \quad (17)$$

donde $a \in \mathbb{R}^{K_0}$ y $B \in \mathbb{R}^{K_0 \times K_0}$. La estimación se realiza por mínimos cuadrados con regularización cuadrática:

$$(\hat{a}, \hat{B}) = \arg \min_{a, B} \sum_t \|Z_{t+1} - a - BZ_t\|_2^2 + \lambda_{\text{var}} \|B\|_F^2, \quad \lambda_{\text{var}} > 0.$$

Pronóstico para el horizonte h . El pronóstico iterado se obtiene aplicando recursivamente (17):

$$\hat{Z}_{t+h|t}^{\text{VAR}} = \hat{a} + \hat{B} \hat{Z}_{t+h-1|t}^{\text{VAR}}, \quad \hat{Z}_{t|t}^{\text{VAR}} = Z_t.$$

La superficie pronosticada se reconstruye por

$$\hat{y}_{t+h|t}^{\text{VAR}} = \hat{y}(\hat{Z}_{t+h|t}^{\text{VAR}}). \quad (18)$$

Este modelo captura dependencia temporal *lineal* y correlación cruzada entre componentes de Z_t , pero no modela no linealidad.

3.7.4. ARH(1) en incrementos de puntajes (ARH-inc)

Para aislar el valor añadido de la regresión por núcleo, se considera una dinámica con persistencia del estado como componente sistemática (equivalentemente $E[Z_{t+1} | Z_t] = Z_t$) y se modela únicamente la dependencia temporal en los incrementos. Se define

$$\Delta Z_t = Z_t - Z_{t-1}. \quad (19)$$

Se supone que $\{\Delta Z_t\}$ satisface una dinámica ARH(1) finito-dimensional:

$$\Delta Z_{t+1} = \rho \Delta Z_t + u_{t+1}, \quad u_t \text{ ruido blanco en } \mathbb{R}^{K_0}. \quad (20)$$

La estimación de ρ se obtiene mediante un análogo regularizado de Yule–Walker:

$$\hat{\rho} = \hat{C}_1(\hat{C}_0 + \lambda_\rho I)^{-1}, \quad \lambda_\rho > 0,$$

donde

$$\hat{C}_0 = \frac{1}{T'} \sum_t \Delta Z_t \Delta Z_t^\top, \quad \hat{C}_1 = \frac{1}{T'} \sum_t \Delta Z_{t+1} \Delta Z_t^\top.$$

Pronóstico para el horizonte h . De (20) se obtiene $E[\Delta Z_{t+k} | \Delta Z_t] = \hat{\rho}^k \Delta Z_t$. Como $Z_{t+h} = Z_t + \sum_{k=1}^h \Delta Z_{t+k}$, el pronóstico queda:

$$\hat{Z}_{t+h|t}^{\text{ARH-inc}} = Z_t + \sum_{k=1}^h \hat{\rho}^k \Delta Z_t, \quad h \geq 1. \quad (21)$$

La superficie pronosticada se reconstruye como

$$\hat{y}_{t+h|t}^{\text{ARH-inc}} = \hat{y} \left(\hat{Z}_{t+h|t}^{\text{ARH-inc}} \right). \quad (22)$$

Este modelo incorpora memoria temporal en los incrementos, pero no incluye una media condicional no lineal. Si el modelo *kernel+ARH(1)* supera a *ARH-inc*, la mejora se atribuye principalmente a la capacidad de capturar no linealidad en $E[Z_{t+1} | Z_t]$.

3.7.5. Resumen de modelos y comparabilidad

En síntesis, los modelos evaluados en la Sección 5 son:

- **PM** (persistencia en malla): (15).

- **PA** (persistencia ajustada): (16).
- **VAR** (VAR(1) en puntajes): (17)–(18).
- **ARH-inc** (ARH(1) en incrementos): (20)–(22).
- **Kernel+ARH(1)** (modelo principal): Sección 3.6.

Todos los modelos que operan en $\mathbb{R}^{K_0}$ se conectan con el espacio de superficies a través del mismo operador de reconstrucción (14). Por tanto, las diferencias entre modelos provienen exclusivamente de la forma de pronosticar Z_{t+h} .

Métrica de evaluación

El desempeño se evalúa mediante el error cuadrático medio en la malla:

$$\text{RMSE}(t, h) = \sqrt{\frac{1}{n} \sum_{q=1}^n (\hat{y}_{t+h|t,q} - y_{t+h,q})^2}. \quad (23)$$

4. Aplicación: Componentes Principales Funcionales de las SVI

4.1. Descripción de los Datos

Fuente y periodo:

Las superficies se obtienen de Bloomberg mediante la función `VOLC` para divisas. A partir del 04 de febrero de 2025, Bloomberg publica mallas diarias completas y regulares en delta y vencimiento para los pares de divisas de interés, principalmente USD/PEN (Dólar vs. Sol Peruano). Para asegurar máxima homogeneidad y ausencia de valores faltantes, se trabaja con las últimas 128 jornadas hábiles del periodo disponible, hasta el 31 de julio de 2025.

Construcción de la superficie:

Por cada día, se poseen las cotizaciones estándar *ATM* (at-the-money), *risk reversal* (RR) y *butterfly* (BF) en los niveles de delta 10 y 25. Sea σ_{ATM} la volatilidad at-the-money, y σ_{xC} , σ_{xP} las volatilidades de call/put con delta $x \in \{10, 25\}$. Se utilizan las identidades habituales:

$$\text{RR}_x = \sigma_{xC} - \sigma_{xP}, \quad \text{BF}_x = \frac{\sigma_{xC} + \sigma_{xP}}{2} - \sigma_{\text{ATM}}.$$

Resolviendo las ecuaciones, se recuperan las volatilidades de puts y calls:

$$\sigma_{xC} = \sigma_{\text{ATM}} + \text{BF}_x + \frac{1}{2}\text{RR}_x, \quad \sigma_{xP} = \sigma_{\text{ATM}} + \text{BF}_x - \frac{1}{2}\text{RR}_x.$$

Con esto, para cada día, se construye la superficie completa en cinco niveles de moneyness/delta:

$$\{25P, 10P, ATM, 10C, 25C\}.$$

Vencimientos:

Se emplean 13 vencimientos estándar por día

$$\{1W, 2W, 1M, 2M, 3M, 6M, 9M, 1Y, 18M, 2Y, 3Y, 4Y, 5Y\}.$$

Donde W significa semana ($1W = 1$ semana), M significa mes ($1M = 1$ mes) y Y significa año ($1Y = 1$ año)

La combinación de 5 niveles de delta y 13 tenores define una malla 5×13 sin datos faltantes para cada fecha del panel.

Pares de divisas:

Se usa la notación BASE/CONTRA. Por ejemplo, en USD/PEN, la volatilidad implícita corresponde a opciones cuyo subyacente es el tipo de cambio del dólar estadounidense por sol peruano. Las divisas analizadas son:

- USD/PEN: dólar estadounidense / sol peruano (Perú)
- USD/COP: dólar estadounidense / peso colombiano (Colombia)
- USD/CLP: dólar estadounidense / peso chileno (Chile)
- USD/BRL: dólar estadounidense / real brasileño (Brasil)
- USD/ARS: dólar estadounidense / peso argentino (Argentina)
- USD/MXN: dólar estadounidense / peso mexicano (México)
- EUR/USD: euro / dólar estadounidense (referencia de mercado desarrollado)
- USD/ZAR: dólar estadounidense / rand sudafricano (referencia de mercado emergente fuera de Latinoamérica)

En todos los casos, las superficies de volatilidad se construyen sobre la misma rejilla de 5 niveles de delta (put 25 %, put 10 %, ATM, call 10 %, call 25 %) por 13 vencimientos, lo que facilita la comparación entre pares de divisas.

El conjunto de datos resultante es un panel diario donde, para cada par de divisas y cada fecha t , se observa una superficie de volatilidad implícita en una malla fija (δ, τ) de dimensión 5×13 . Esta regularidad permite la proyección directa en la base B-spline tensorial y la aplicación de FPCA sobre superficies bidimensionales.

4.2. Preprocesamiento y conformación del panel

Estructura de datos:

Cada día t y cada par $\mathcal{M}$ generan una matriz 5×13 de volatilidades $\sigma(\delta, \tau)$ en la rejilla de cinco deltas $\{25P, 10P, ATM, 10C, 25C\}$ por trece tenores. El panel se transforma a formato largo con campos moneda, fecha, δ, τ, σ .

Conversión de tenores:

Se mapea $\tau \mapsto t$ (años) para unificar la escala temporal:

$$t(1W) = \frac{1}{52}, \quad t(1M) = \frac{1}{12}, \quad t(1Y) = 1, \text{ etc.}$$

Convención de orden:

Se fija el orden de deltas 25P, 10P, ATM, 10C, 25C y el orden creciente de tenores, de modo que el vectorizado sea reproducible. Para ilustrar la malla y la estabilidad de la rejilla en el par USD/PEN, véase la Fig. 1.




Figura 1: Curvas $\tau \mapsto \sigma(\delta, \tau)$ por fecha para USD/PEN y por cada delta. Cada línea gris corresponde a un día; la línea azul muestra la tendencia promedio por delta.

4.3. Ajuste diario sobre base B-spline tensorial

Cada superficie diaria de volatilidad $\sigma^{(t)}(\delta, \tau)$ se aproxima en un espacio finito generado por el producto tensorial de dos bases B-spline cúbicas, una por eje.

Bases unidimensionales:

Sea $\Phi_\delta \in \mathbb{R}^{5 \times K_\delta}$ la matriz de evaluación de la base B-spline en el eje de δ (cinco niveles) y $\Phi_\tau \in \mathbb{R}^{13 \times K_\tau}$ la correspondiente al eje de τ (trece tenores). Los grados de libertad K_δ y K_τ se fijarán mediante diagnósticos formales en la sección de validación.

Diseño de Kronecker:

La base bidimensional se construye como producto tensorial. Si $y^{(t)} = \text{vec } \sigma^{(t)} \in \mathbb{R}^{65}$ es la vectorización columna-a-columna de la malla (ordenando τ de menor a mayor dentro de cada nivel de δ), entonces el diseño es

$$X = \Phi_\tau \otimes \Phi_\delta \in \mathbb{R}^{65 \times K}, \quad K = K_\delta K_\tau.$$

Estimación de coeficientes:

Para cada día t , los coeficientes $\hat{\mathbf{c}}^{(t)} \in \mathbb{R}^K$ se obtienen por mínimos cuadrados ordinarios,

$$\hat{\mathbf{c}}^{(t)} = (X^\top X)^{-1} X^\top y^{(t)},$$

y la superficie ajustada se recupera como $\hat{y}^{(t)} = X \hat{\mathbf{c}}^{(t)}$, que reacomodada a formato 5×13 entrega $\hat{\sigma}^{(t)}(\delta, \tau)$.

Métrica funcional:

Para respetar el producto interno $L^2(\Delta \times T)$ en etapas posteriores, se utiliza la métrica inducida por las matrices de Gram unidimensionales,

$$G_\delta = \int B_\delta B_\delta^\top, \quad G_\tau = \int B_\tau B_\tau^\top, \quad G = G_\tau \otimes G_\delta,$$

cuyo factor de Cholesky $G = S^\top S$ se empleará en la FPCA sobre coeficientes.

A modo ilustrativo, la Figura 2 muestra el ajuste $\hat{\sigma}(\delta, \tau)$ obtenido para un día seleccionado al azar en USD/PEN; los contornos representan niveles de volatilidad (en %) y se reporta el RMSE diario calculado sobre la rejilla 5×13 .




Figura 2: Superficie de volatilidad implícita ajustada $\hat{\sigma}(\delta, \tau)$ para USD/PEN en un día al azar. Los colores indican niveles de volatilidad (%), con curvas de nivel sobre la rejilla de cinco deltas (-25% , -10% , ATM, $+10\%$, $+25\%$) y trece tenores (de 1W a 5Y). El valor RMSE mostrado corresponde al error cuadrático medio del ajuste en ese día, calculado sobre los 5×13 puntos de la rejilla.

4.4. FPCA de superficies en la métrica funcional

Centrado y transformación métrica:

Sea $\hat{\mathbf{c}}^{(t)} \in \mathbb{R}^K$ el vector de coeficientes (base B-spline tensorial) que representa la SVI del día t . Se centra por columna,

$$\tilde{\mathbf{c}}^{(t)} = \hat{\mathbf{c}}^{(t)} - \bar{\mathbf{c}}, \quad \bar{\mathbf{c}} = \frac{1}{T} \sum_t \hat{\mathbf{c}}^{(t)}.$$

Para respetar el producto interno $L^2(\Delta \times T)$ inducido por la base no ortonormal, se usa la métrica $G = G_\tau \otimes G_\delta$, con descomposición de Cholesky $G = S^\top S$. La representación en coordenadas euclidianas es

$$\mathbf{u}^{(t)} = S \tilde{\mathbf{c}}^{(t)} \in \mathbb{R}^K.$$

PCA euclidiana y mapeo inverso:

Se aplica PCA a la matriz con filas $\{\mathbf{u}^{(t)}\}_t$. Si $\mathbf{w}_k$ es el k -ésimo autovector euclidiano (normalizado), el autovector en el espacio de coeficientes es

$$\mathbf{v}_k = S^{-1} \mathbf{w}_k, \quad \|\mathbf{v}_k\|_G^2 = \mathbf{v}_k^\top G \mathbf{v}_k = 1,$$

y los puntajes diarios se obtienen como $\xi_k^{(t)} = \mathbf{u}^{(t)\top} \mathbf{w}_k$.

Reconstrucción y visualización:

Dada la base bidimensional $X = \Phi_\tau \otimes \Phi_\delta$, la k -ésima eigen-superficie es $\varphi_k(\delta, \tau) = X \mathbf{v}_k$. Con K_0 componentes,

$$\hat{\sigma}_{K_0}^{(t)}(\delta, \tau) = \hat{\mu}(\delta, \tau) + \sum_{k=1}^{K_0} \xi_k^{(t)} \varphi_k(\delta, \tau), \quad \hat{\mu}(\delta, \tau) = X \bar{\mathbf{c}}.$$

Componentes Principales:

Los resultados de la descomposición se muestran en la siguiente tabla:

Par	PC1	PC2	PC3	PC4	PC5
USD/PEN	0.8713	0.1216	0.0044	0.0026	0.0001
USD/COP	0.9264	0.0653	0.0075	0.0005	0.0002
USD/CLP	0.8378	0.1601	0.0014	0.0006	0.0000
USD/BRL	0.8476	0.1499	0.0020	0.0003	0.0001
USD/ARS	0.7992	0.1949	0.0038	0.0017	0.0003
USD/MXN	0.9426	0.0543	0.0027	0.0002	0.0001
EUR/USD	0.9613	0.0322	0.0060	0.0004	0.0001
USD/ZAR	0.9667	0.0322	0.0006	0.0005	0.0000

Cuadro 1: Proporción de varianza explicada (FVE) por componente principal y par de divisas.

En todos los pares, PC1 domina (80–97 %): un factor de nivel que desplaza la superficie casi paralelamente (más intensa cerca de ATM y persistente a lo largo de los vencimientos). PC2 aporta entre 3–20 % según el par y suele corresponder a inclinación/*tilt* (movimientos diferenciales entre puts OTM y calls OTM y/o un sesgo por vencimiento). PC3 es residual (en general < 1 %), asociado a curvatura/ alas de la superficie. En consecuencia, reconstrucciones con $K_0 = 2$ capturan casi toda la variabilidad, y $K_0 = 3$ refina el ajuste de alas sin sobreparametrizar.

Las diferencias entre las varianzas explicadas de los PC1 y PC2 entre pares de divisas tienen una interpretación económica:

- EUR/USD y USD/ZAR (PC1 $\approx$ 96-97 %): Mercados desarrollados (EUR/USD) o emergentes pero líquidos (USD/ZAR) exhiben una dinámica dominada por shocks de nivel de volatilidad; cambios globales en incertidumbre macro y política monetaria internacional, con menor participación de skew/curvatura. La microestructura (spreads

estrechos, profundidad) y el Δ -hedging frecuente estabilizan la forma relativa de la SVI; por eso PC2 y PC3 pesan poco.

- USD/MXN y USD/COP (PC1 93-95 %): Pares líquidos de Latinoamérica; el nivel explica casi toda la variación. La menor PC2 sugiere que las variaciones de *skew* son acotadas; efectos de *carry*, flujos corporativos estacionales y un régimen cambiario de flotación limpia aparecen principalmente vía nivel (PC1).
- USD/PEN, USD/CLP, USD/BRL (PC1 84–87 %, PC2 12–16 %): Aquí PC2 es más relevante. Algunas posibles causas son intervenciones discrecionales (manejo de bandas implícitas), sensibilidad de las colas a shocks de términos de intercambio (commodities en CLP y BRL) y profundidad desigual por cada vencimiento. El resultado es un *tilt* más activo (asimetría put-call y/o term-tilt), que eleva la varianza explicada por la PC2.
- USD/ARS (PC1 80 %, PC2 19.5 %): El peso de PC2 apunta a episodios de reconfiguración de *skew* y desalineamientos por vencimiento, consistentes con controles de capital, un régimen cambiario discrecional y saltos de régimen (ej. devaluaciones).

Estabilidad subespacial:

Para evaluar estabilidad de las direcciones principales, se compara el subespacio generado por PC1-PC3 en toda la muestra con el de una submuestra reciente de $W = 50$ días, usando la distancia de proyecciones (norma de Frobenius). Para USD/PEN se obtiene $\text{dist} = 0,212$, lo que sugiere buena estabilidad de las primeras tres PCs en la ventana reciente (valores cercanos a 0 indican subespacios muy similares).

Eigensuperficies ($\hat{\mu} \pm 1$ DE):

Las Figuras 3–5 muestran las deformaciones de la superficie media $\hat{\mu}(\delta, \tau)$ al moverse ± 1 desviación estándar a lo largo de cada componente principal. Los ejes son *Tenor* (años) en el eje x y *Delta* en el eje y ; la escala de color indica variación de volatilidad en puntos porcentuales.

En USD/PEN, (i) PC1 es un factor de nivel con sesgo de *skew*: el impacto es mayor en el ala put y en los tenores largos (4-5Y), consistente con su FVE dominante; (ii) PC2 genera un *tilt* en las alas vs. ATM, más visible en el tramo largo; (iii) PC3 modula la curvatura local en torno a 2-3 años.




Figura 3: Eigensuperficie PC1 para USD/PEN: $\hat{\mu} \pm 1$ DE.




Figura 4: Eigensuperficie PC2 para USD/PEN: $\hat{\mu} \pm 1$ DE.




Figura 5: Eigensuperficie PC3 para USD/PEN: $\hat{\mu} \pm 1$ DE.

Perfiles por tenor a delta fijo:

Las figura 6 muestra $\tau \mapsto \hat{\sigma}(\delta, \tau)$ para cinco deltas en dos fechas (USD/PEN). Se observa suavidad por tenor y coherencia entre deltas; además, los patrones son consistentes con las eigensuperficies: PC1 desplaza casi en paralelo las curvas y PC2 se manifiesta como separación de las alas vs. ATM en el tramo de vencimientos largos.




Figura 6: Perfiles por tenor a delta fijo (USD/PEN). Arriba: 2025-02-04; abajo: 2025-07-31. Las variaciones casi paralelas reflejan PC1; la separación de alas frente a ATM en el largo refleja PC2.

5. Modelos dinámicos en puntajes FPCA con dependencia autorregresiva

Este capítulo evalúa empíricamente, para USD/PEN, (i) el piso de error asociado a la representación funcional (ajuste por base), y (ii) el desempeño *fuera de muestra* (out-of-sample, OOS) de los modelos dinámicos descritos en el Capítulo 3, en distintos horizontes de pronóstico.

5.1. Diseño del backtest OOS y modelos comparados

Ventana temporal y horizonte. Se utiliza la muestra diaria de USD/PEN descrita en el Capítulo 4 (malla 5×13), con un esquema de pronóstico móvil que emplea un periodo inicial de entrenamiento de 80 días y evalúa horizontes $h \in \{1, 5, 10\}$.

Métrica. El error se mide sobre la malla fija mediante:

$$\text{RMSE}(t, h) = \sqrt{\frac{1}{n} \sum_{q=1}^n (\hat{y}_{t+h|t,q} - y_{t+h,q})^2}, \quad n = 65.$$

Se reporta la mediana de $\text{RMSE}(t, h)$ en el tramo OOS, junto con distribuciones (diagramas de caja) y un indicador de robustez.

Modelos. Se comparan:

- **PM** (persistencia en malla observada), Ec. (3.31).
- **PA** (persistencia de la superficie ajustada por base), Ec. (3.32).
- **VAR** (VAR(1) en puntajes), Ec. (3.33)–(3.34).
- **ARH-inc** (ARH(1) en incrementos de puntajes), Ec. (3.35)–(3.36).
- **Kernel+ARH(1)** (modelo principal), Sección 3.5.

Antes de comparar dinámicas, es útil cuantificar el error asociado únicamente a la representación diaria por base tensorial. En USD/PEN, el ajuste interno en la malla es alto: la RMSE mediana del ajuste por base es 0.0073 pp. Este valor actúa como un piso aproximado impuesto por ruido de mercado y error de representación; en consecuencia, las diferencias entre modelos dinámicos deben interpretarse frente a un error OOS que es, en general, un orden de magnitud mayor.

5.2. Elección de K_0

En esta tesis, K_0 cumple dos roles distintos:

- $K_0^{(\text{rep})}$: dimensión para *reconstrucción/compresión* (Capítulo 4).
- $K_0^{(\text{dyn})}$: dimensión para *predicción*.

Para dinámica, K_0 se interpreta como un hiperparámetro de regularización: incluir componentes de baja señal (alta frecuencia) puede degradar el pronóstico OOS al introducir variación no

predecible en los puntajes y dificultar la estimación (en especial en métodos basados en distancias).

Selección empírica por horizonte. Con base en la curva de sensibilidad (Fig. 7), se elige:

$$K_0^{(\text{dyn})}(5) = 5, \quad K_0^{(\text{dyn})}(10) = 3,$$

mientras que para $h = 1$ se mantiene el benchmark PM como referencia dominante, y los modelos dinámicos no muestran mejoras robustas.




Figura 7: Sensibilidad OOS: mediana de RMSE vs K_0 para USD/PEN en $h \in \{1, 5, 10\}$. La selección dinámica privilegia compresión fuerte: $K_0 \in \{3, 5\}$ según horizonte.

5.3. Resultados principales OOS

Esta sección reporta los resultados OOS centrándose en las configuraciones relevantes para pronóstico. La Tabla 2 resume la RMSE mediana por horizonte. En $h = 5$ se reportan modelos en $K_0 = 5$; en $h = 10$, en $K_0 = 3$.

Cuadro 2: USD/PEN: RMSE mediana OOS por horizonte usando $K_0^{(\text{dyn})}$ (puntajes truncados).

Modelo	$h = 1$ ($K_0 = 10$)	$h = 5$ ($K_0 = 5$)	$h = 10$ ($K_0 = 3$)
PM (persistencia)	0.0784	0.220	0.361
PA (persistencia ajust.)	0.0787	0.220	0.361
VAR1 (VAR(1) ridge)	0.110	0.230	0.324
ARH-inc (incrementos)	0.0887	0.201	0.270
KernelARH	0.161	0.263	0.281

- Horizonte $h = 1$: A un día, la SVI es altamente persistente: PM y PA constituyen un benchmark difícil de superar. En este horizonte, el costo de estimar dinámica (y el riesgo de sobreajuste) domina cualquier ganancia marginal. De hecho, aun bajo $K_0 \leq 10$, los modelos dinámicos empeoran la mediana: ARH-inc alcanza 0.0887 y VAR1 0.110 (vs. 0.0784 de PM), por lo que el resultado operativo es utilizar persistencia.
- Horizonte $h = 5$: Con compresión moderada ($K_0 = 5$), aparece señal dinámica explotable. En particular, ARH-inc reduce la RMSE mediana de 0.220 (PM) a **0.201**, una mejora relativa de aproximadamente $1 - 0,201/0,220 \approx 8,6\%$. Este patrón sugiere que, a 5 días, parte de la dinámica de los factores es predecible si se filtra adecuadamente la alta frecuencia.
- Horizonte $h = 10$: La ganancia más marcada ocurre a 10 días bajo compresión fuerte. ARH-inc con $K_0 = 3$ reduce la RMSE mediana desde 0.361 (PM) a **0.270** (mejora $\approx 25,2\%$). El modelo Kernel+ARH(1) también mejora con $K_0 = 3$ (RMSE mediana 0.281; mejora $\approx 22,2\%$), aunque su robustez (ver tasa de aciertos) es menor que la de ARH-inc en esta muestra. VAR1 también mejora en mediana a $h = 10$ (0.324), pero su desempeño es más sensible (ver distribución/episodios de error).

5.4. Robustez: distribución de errores y tasa de aciertos

Distribuciones. Para complementar la mediana, las Figuras 8–9 reportan (i) series temporales de RMSE OOS y (ii) diagramas de caja por modelo, respectivamente. En particular, el modelo VAR tiende a exhibir episodios de error elevado (picos) en horizontes mayores, consistente con sensibilidad a estimación en muestras cortas y/o a cambios de régimen (aun cuando su mediana pueda ser competitiva en $h = 10$).




Figura 8: USD/PEN: series temporales de RMSE OOS por horizonte y modelo (configuración principal con $K_0^{(\text{dyn})}$).




Figura 9: USD/PEN: diagrama de cajas de RMSE OOS por horizonte y modelo (configuración principal con $K_0^{(\text{dyn})}$).

Tasa de Aciertos: Se define como:

$$\text{TA}(h) = \frac{1}{|\mathcal{T}_{\text{OOS}}|} \sum_{t \in \mathcal{T}_{\text{OOS}}} \mathbb{1}_{\left\{ \text{RMSE}_{\text{modelo}}(t, h) < \text{RMSE}_{\text{PM}}(t, h) \right\}}.$$

En USD/PEN, la tasa de aciertos confirma que las mejoras a horizontes medianos/largos no provienen de pocos outliers, sino que son relativamente sistemáticas cuando se usa baja dimensión. En particular:

- Para $h = 10$, ARH-inc alcanza valores de hasta $\approx 0,72$ (con $K_0 = 3$) y $\approx 0,80$ (con $K_0 = 5$).
- Para $h = 5$, ARH-inc sube hasta $\approx 0,73$ (con $K_0 = 5$).
- Kernel+ARH(1) tiende a ubicarse alrededor de $\approx 0,46$ – $0,51$ en $h = 10$ (menor robustez en comparación con ARH-inc).

Los resultados OOS para USD/PEN apuntan a tres conclusiones empíricas:

- A 1 día domina la persistencia. PM y PA capturan casi toda la señal relevante; la dinámica estimada no mejora de forma robusta (incluso con $K_0 = 10$).
- A horizontes medianos/largos, la baja dimensión manda. La compresión a $K_0 \in \{3, 5\}$ filtra alta frecuencia no predecible y permite capturar la dinámica macro de la superficie.
- Modelos simples generalizan mejor en esta muestra. ARH-inc obtiene las mejoras más consistentes en mediana y en tasa de aciertos; Kernel+ARH(1) puede mejorar a $h = 10$ con K_0 pequeño, pero es menos robusto. VAR1 puede ser competitivo en mediana a $h = 10$, aunque muestra mayor sensibilidad en la distribución de errores.

Para USD/PEN, con la muestra y el diseño OOS evaluados:

- Pronóstico $h = 1$: usar PM o PA.
- Pronóstico $h = 5$: usar ARH-inc con $K_0 = 5$ (mejora mediana ≈ 8 – 9% frente a PM).
- Pronóstico $h = 10$: usar ARH-inc con $K_0 = 3$ (mejora mediana $\approx 25\%$ frente a PM). Kernel+ARH(1) con $K_0 = 3$ es alternativa competitiva en mediana, aunque menos robusta por tasa de aciertos.

6. Conclusiones

Esta tesis abordó el problema de representar y pronosticar superficies de volatilidad implícita (SVI) en mercados latinoamericanos, donde la microestructura (liquidez limitada, dispersión de cotizaciones y cambios de régimen) dificulta la aplicación robusta de modelos paramétricos clásicos. La contribución central fue construir un marco funcional coherente,

desde la representación hasta la predicción, que permite trabajar con superficies como objetos en un espacio $L^2(\Delta \times T)$, manteniendo control explícito sobre la métrica, la estabilidad numérica y la reducción de dimensión.

El primer aporte metodológico es la representación funcional bidimensional de las SVI mediante bases B-spline tensoriales, que entrega una parametrización flexible con soporte local y permite estabilizar superficies diarias aun cuando el muestreo sea escaso o irregular en otros contextos. Más importante aún, esta representación se integró con una corrección métrica explícita basada en la matriz de Gram y su factorización de Cholesky, garantizando que la descomposición en componentes principales se realice en la geometría natural del problema (L^2) y no en un espacio euclidiano arbitrario de coeficientes. En términos prácticos, este punto evita que la base no ortonormal distorsione la noción de variabilidad y las proyecciones, un detalle técnico que es a la vez esencial para la interpretación y para la predicción.

El segundo aporte metodológico es operacional: al combinar (i) representación por base, (ii) FPCA en la métrica correcta y (iii) modelamiento temporal de puntajes, se obtiene un flujo que separa con claridad tres fuentes de error: error de medición/ajuste, error de truncación (compresión) y error de pronóstico dinámico. Esta separación es valiosa porque permite diagnosticar en qué tramo el modelo gana o pierde; es decir, si el límite práctico proviene del ajuste diario por base (ruido/representación), de la dimensión retenida (truncación) o de la capacidad predictiva del modelo temporal sobre los factores.

En el bloque empírico, el hallazgo principal es que la predictibilidad de la SVI depende fuertemente del horizonte. Para USD/PEN, a un día ($h = 1$) domina la persistencia: los modelos PM/PA establecen un benchmark que no es superado de manera robusta. En cambio, a horizontes medianos y largos ($h = 5$ y $h = 10$), la reducción de dimensión se vuelve determinante: al trabajar con K_0 pequeño (compresión fuerte), el modelo dinámico es efectivo y se obtienen mejoras fuera de muestra. En particular, el modelo ARH-inc logra el desempeño más consistente en esta muestra (mejoras de magnitud relevante en mediana y con tasas de acierto elevadas), lo que sugiere que una parte importante de la dinámica predecible se concentra en la evolución de incrementos de los factores, más que en la forma funcional completa día a día.

Un resultado igualmente informativo es que el modelo no paramétrico Kernel+ARH(1), aunque conceptualmente atractivo por permitir no linealidad en la media condicional, no dominó a los benchmarks lineales simples en este panel. En términos prácticos, esto es consistente con (i) el tamaño muestral relativamente corto para estimación local en dimensión K_0 , (ii) la sensibilidad del suavizador a la elección de ancho de banda y a la escala relativa de puntajes, y (iii) la presencia potencial de cambios de régimen, donde las observaciones cercanas en el espacio de puntajes pueden no ser informativos para el futuro inmediato. En

síntesis: en este caso, la ganancia vino más de regularizar (a bajas dimensiones) y de modelar los errores de forma autorregresiva que de introducir no linealidad vía kernel.

Desde el punto de vista aplicado, la tesis entrega una recomendación operativa clara para USD/PEN bajo el diseño evaluado: (i) para $h = 1$, utilizar persistencia (PM/PA); (ii) para $h = 5$, un modelo parsimonioso en puntajes con dependencia en incrementos (ARH-inc) con compresión moderada; y (iii) para $h = 10$, compresión fuerte y dinámica simple (ARH-inc) como primera opción, con Kernel+ARH(1) como alternativa competitiva en mediana pero menos robusta. Estas conclusiones no deben interpretarse como universales, sino como evidencia empírica concreta en un mercado emergente con malla fija y periodo limitado, donde los costos de estimación y el riesgo de sobreajuste son especialmente relevantes.

6.1. Limitaciones

Esta investigación presenta limitaciones que delimitan el alcance de las inferencias:

- Tamaño y ventana temporal: el panel considerado (128 días hábiles) restringe la estabilidad de estimaciones dinámicas, especialmente para métodos no paramétricos y para operadores ρ en dimensión moderada. Con el paso del tiempo, se tendrán paneles de datos más extensos.
- Enfoque en USD/PEN: aunque se documenta la estructura FPCA para múltiples pares, la evaluación dinámica se concentra en USD/PEN; por tanto, la evidencia de pronóstico no se generaliza automáticamente a otras divisas.
- Predictores endógenos: el pronóstico se realiza únicamente con información interna de la SVI. No se incorporan variables exógenas (spot, tasas, carry, commodities, eventos), que podrían ser determinantes a horizontes mayores.
- Restricciones de no-arbitraje: el enfoque se centra en precisión predictiva sobre malla fija; no impone explícitamente restricciones de convexidad/monotonía o no-arbitraje en toda la superficie, lo cual puede ser relevante para aplicaciones de valorización y determinación de precios.

6.2. Líneas de investigación futura

Los resultados abren rutas naturales de extensión:

- Panel más largo y validación multi-par: extender la muestra y evaluar sistemáticamente en USD/CLP, USD/BRL, USD/COP, etc., para identificar regularidades y heterogeneidad

por microestructura.

- Modelos dinámicos con cambios de régimen: introducir dinámicas tipo cambio de régimen Markov o modelos con parámetros que varían en el tiempo para capturar episodios de intervención estatal, escenarios de estrés o shocks económicos.
- Predicción directa multi-horizonte: contrastar pronóstico iterado vs pronóstico directo (estimando $E[Z_{t+h} | Z_t]$) para reducir acumulación de error a h grande.
- Kernel adaptativo y selección de banda: emplear anchos de banda adaptativos (por densidad local) y criterios de selección OOS específicos por horizonte para mitigar la inestabilidad del suavizado.
- Variables exógenas y modelos híbridos: incluir información macro/de mercado (spot, diferencial de tasas, términos de intercambio) en modelos tipo VARX o regresión funcional con covariables.
- Restricciones de forma/no-arbitraje: integrar penalizaciones o proyecciones que impongan regularidad económica en la superficie completa.

En conclusión, la tesis muestra que, en un mercado latinoamericano con mallas densas recientemente disponibles, un enfoque funcional con métrica correcta permite una representación estable y una interpretación parsimoniosa de factores latentes. En cuanto al modelamiento dinámico, la evidencia sugiere que la clave práctica es controlar complejidad (baja dimensión) y modelar memoria de forma simple y robusta, antes que introducir sofisticación no paramétrica en muestras cortas. Esto proporciona un marco reproducible tanto para investigación futura como para aplicaciones en mesas de derivados orientadas a pronóstico y gestión de riesgo.

Referencias

- Aue, A., Norinho, D. D., & Hörmann, S. (2015). On the Prediction of Stationary Functional Time Series. *Journal of the American Statistical Association*, 110(509), 378-392. <https://doi.org/10.1080/01621459.2014.909317>
- Avellaneda, M., Healy, B., Papanicolaou, A., & Papanicolaou, G. (2020, enero). PCA for Implied Volatility Surfaces [arXiv:2002.00085 [q-fin]]. <https://doi.org/10.48550/arXiv.2002.00085>
- Bosq, D. (2000). *Linear Processes in Function Spaces* (P. Bickel, P. Diggle, S. Fienberg, K. Krickeberg, I. Olkin, N. Wermuth & S. Zeger, Eds.; Vol. 149). Springer New York. <https://doi.org/10.1007/978-1-4612-1154-9>
- Bosq, D., & Blanke, D. (2007, octubre). *Inference and Prediction in Large Dimensions* (1.^a ed.). Wiley. <https://doi.org/10.1002/9780470724033>
- Cont, R., & Da Fonseca, J. (2002). Dynamics of Implied Volatility Surfaces. *Quantitative Finance*, 2(1), 45-60. <https://doi.org/10.1088/1469-7688/2/1/304>
- de Boor, C. (2001). *A Practical Guide to Splines* (Revised, Vol. 27). Springer. <https://doi.org/10.1137/1022106>
- Eilers, P. H. C., & Marx, B. D. (2003). Multivariate calibration with temperature interaction using two-dimensional penalized signal regression. *Chemometrics and Intelligent Laboratory Systems*, 66(2), 159-174. [https://doi.org/10.1016/S0169-7439\(03\)00029-7](https://doi.org/10.1016/S0169-7439(03)00029-7)
- Fahrmeir, L., & Tutz, G. (2001). *Multivariate Statistical Modelling Based on Generalized Linear Models* (2.^a ed.). Springer. <https://doi.org/10.1007/978-1-4757-3454-6>
- Fengler, M. R., Härdle, W. K., & Villa, C. (2003). The Dynamics of Implied Volatilities: A Common Principal Components Approach. *Review of Derivatives Research*, 6(3), 179-202. <https://doi.org/10.1023/B:REDR.0000004823.77464.2d>
- Ferraty, F., & Vieu, P. (2006). *Nonparametric Functional Data Analysis: Theory and Practice*. Springer.
- Grith, M., Wagner, H., Härdle, W. K., & Kneip, A. (2018). Functional Principal Component Analysis for Derivatives of Multivariate Curves. *Statistica Sinica*. <https://doi.org/10.5705/ss.202017.0199>
- Hagan, P., Kumar, D., Lesniewski, A., & Woodward, D. (2002). Managing Smile Risk. *Wilmott Magazine*, 1, 84-108. Consultado el 12 de junio de 2025, desde https://www.next-finance.net/IMG/pdf/pdf_SABR.pdf
- Heston, S. L. (1993). A Closed-Form Solution for Options with Stochastic Volatility with Applications to Bond and Currency Options. *Review of Financial Studies*, 6(2), 327-343. <https://doi.org/10.1093/rfs/6.2.327>
- Jaimungal, S., & Ng, E. K. H. (2007). Consistent Functional PCA for Financial Time-Series. *Proceedings of the Fourth IASTED International Conference on Financial Engineering*

- and Applications, 103-108. <https://www.utstat.toronto.edu/sjaimung/papers/VAR-FPCA.pdf>
- James, G., Hastie, T., & Sugar, C. (2000). Principal Component Models for Sparse Functional Data. *Biometrika*, 87(3), 587-602. <https://doi.org/10.1093/biomet/87.3.587>
- Kearney, F., Cummins, M., & Murphy, F. (2018). Forecasting Implied Volatility in Foreign Exchange Markets: A Functional Time Series Approach. *The European Journal of Finance*, 24(1), 1-18. <https://doi.org/10.1080/1351847X.2016.1271441>
- Li, C., Xiao, L., & Luo, S. (2020). Fast Covariance Estimation for Multivariate Sparse Functional Data. *Stat*, 9(1), e245. <https://doi.org/10.1002/sta4.245>
- Liang, Z., Weng, F., Ma, Y., Xu, Y., Zhu, M., & Yang, C. (2022). Measurement and Analysis of High Frequency Asset Volatility Based on Functional Data Analysis. *Mathematics*, 10(7), 1140. <https://doi.org/10.3390/math10071140>
- Mas, A., & Pumo, B. (2009). Functional Linear Regression with Derivatives. *Journal of Nonparametric Statistics*, 21(1), 19-40. <https://doi.org/10.1080/10485250802401046>
- Petrovich, J. (2018). *Functional Principal Component Analysis and Sparse Functional Regression* [PhD Thesis]. Pennsylvania State University. https://etda.libraries.psu.edu/files/final_submissions/17278
- Ramsay, J. O., & Silverman, B. W. (2006). *Functional Data Analysis* (2. ed., [Nachdr.]). Springer.
- Reiss, P. T., & Xu, M. (2020). Tensor product splines and functional principal components [Open access]. *Journal of Statistical Planning and Inference*, 208, 1-12. <https://doi.org/10.1016/j.jspi.2019.10.006>
- Ruiz-Medina, M. D., Miranda, D., & Espejo, R. M. (2019). Dynamical Multiple Regression in Function Spaces, Under Kernel Regressors, with ARH(1) Errors. *TEST*, 28(3), 943-968. <https://doi.org/10.1007/s11749-018-0614-2>
- Ruppert, D., Wand, M. P., & Carroll, R. J. (2003). *Semiparametric Regression*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511755453>
- Shang, H. L., & Kearney, F. (2022). Dynamic Functional Time-Series Forecasts of Foreign Exchange Implied Volatility Surfaces. *International Journal of Forecasting*, 38(3), 1025-1049. <https://doi.org/10.1016/j.ijforecast.2021.07.011>
- Sui, C., Lung, P., & Yang, M. (2020). Predictable Dynamics in the Implied Volatility Surface Based on Weighted Least Squares: Evidence from Soybean Meal Futures Options in China. *Emerging Markets Finance and Trade*, 56(11), 2625-2638. <https://doi.org/10.1080/1540496X.2019.1616543>
- Tan, Y., Tan, Z., Tang, Y., & Zhang, Z. (2024). Functional Volatility Forecasting. *Journal of Forecasting*, 43(8), 3009-3034. <https://doi.org/10.1002/for.3170>

- Weaver, C., Perryman, B., Jiang, J., Chien, A., Meoded, E., & Kirk, A. (2020, mayo). *Functional PCA for Implied Volatility Surface Prediction* (inf. téc.). Metlife Investment Management. Consultado el 27 de mayo de 2025, desde https://investments.metlife.com/content/dam/metlifecom/us/investments/insights/research-topics/macro-strategy/pdf/MIM_Functional-PCA-Implied-Volatility-Surface-Prediction_051920.pdf
- Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2.^a ed.). Chapman; Hall/CRC. <https://doi.org/10.1201/9781315370279>